

用臉部肌電圖做中文無聲語音辨識

Neural Chinese Silent Speech Recognition with Facial EMG

Xie et al., 2025 | Speech Communication

整理：陳睿莆 國立虎尾科技大學

目錄

研究背景

- 一、什麼是無聲語音介面 (SSI)
- 二、為什麼用臉部 sEMG
- 三、研究動機與挑戰

資料集與硬體

- 四、資料集介紹
- 五、硬體設備
- 六、電極擺放位置

訊號前處理

- 七、為什麼需要濾波
- 八、Butterworth 濾波器
- 九、Notch 陷波濾波器

特徵萃取與增強

- 十、MFSC 特徵萃取
- 十一～十四、資料增強三種方法

模型架構 (AuxCEMGR)

- 十五～二十一、CNN / Transformer / CTC / GRL

訓練與評估

- 二十二～二十四、訓練設定與 CER

實驗結果

- 二十五～三十一、各項分析

結論

一、什麼是無聲語音介面 (SSI) ？



Fig.1 – EMG 訊號轉文字示意圖

定義：不發出聲音，靠感測器辨識說話意圖 → 轉成文字

應用場景

- 喉嚨受傷者、氣管切開術後無法發聲的病人
- 高噪音環境（工廠、戰場）
- 隱密通訊（不希望他人聽到內容）

為什麼難？

- 靜默 EMG 訊號比有聲弱 **3-5** 倍，訊雜比（SNR）低
- 中文字元龐大（本研究 **667** 個唯一字元）

二、為什麼用臉部 sEMG ?

Fig.2 — 電極擺放位置

sEMG（表面肌電圖）

- 貼在皮膚表面的電極，偵測肌肉收縮時的微弱電訊號
(0.1–5 mV)
- 非侵入式、即時、可穿戴

為什麼臉部？

- 說話時嘴唇、下巴、臉頰、喉部肌肉都會動
- 靜默說話時，肌肉仍有微小收縮，可被偵測

與其他 SSI 技術的比較

- 喉部麥克風：需靠聲帶振動，完全靜默時無效

三、研究動機與挑戰

現有研究的空白

- 現有 sEMG 語音辨識大多針對英文
- 中文 SSI 研究幾乎空白，本文為首篇

中文的特殊挑戰

- 字元空間龐大：667 個唯一字元
- 聲調系統複雜：4 個聲調 + 輕聲
- 同音字多：「ji」→ 雞、機、積...

Session 偏移問題 (Domain Shift)

Session 1: 電極貼在位置 A → 特徵分布 P_1

Session 2: 電極貼在位置 B → 特徵分布 P_2

↓

$P_1 \neq P_2 \rightarrow$ 跨 Session 準確率大幅下降

本研究目標

- 設計能克服以上挑戰的
- 第一個中文臉部 EMG SSI 系統

四、資料集介紹

項目	數值
受試者	1 名成年女性
語料庫	NBA 籃球播報語料
句子數	1,238 句
總字元數	12,584 字
唯一字元	667 個
Session 數	5 個（不同日期）
資料分割	訓練:驗證:測試 = 7:1:2

為什麼只有 1 名受試者？

EMG 資料採集成本高、需要志願者長時間配合，這是當前 SSI 研究的普遍限制。

NBA 語料庫的特點

- 涵蓋日常用語與體育專有名詞
- 句子長度 5–35 字不等
- 字元分布真實，不人工簡化

五、硬體設備 & 電極位置



Fig.2 — 8 通道電極擺放

Neuracle NSW308M

規格	數值
採樣率	1000 Hz
通道數	8 通道
電極材質	Ag/AgCl
訊號振幅	0.1–5 mV

電極位置

- CH1–CH2：上嘴唇兩側（口輪匝肌）

六、訊號前處理流程

① Butterworth 帶通濾波

保留 10–400 Hz

- 去除 < 10 Hz 的基線漂移
- 去除 > 400 Hz 的高頻噪訊
- 4 階（截止斜率夠銳利）

```
from scipy.signal import butter,
b, a = butter(4, [10, 400],
              btype='band', fs=1000)
x = filtfilt(b, a, raw_signal)
```

② Notch 陷波濾波

去除 50/150/250/350 Hz

- 50 Hz：台灣市電工頻
- 150/250/350 Hz：諧波
- $Q=30$ ：陷波夠窄夠精準

```
from scipy.signal import iirnotch
for f0 in [50, 150, 250, 350]:
    b, a = iirnotch(f0, Q=30,
                    fs=1000)
x = filtfilt(b, a, x)
```

③ 分段切割

依句子邊界切成片段

- 每段對應一句話
- 保留原始時序長度
- 用於後續 MFSC 計算

七、MFSC 特徵萃取



Fig.3 — 靜默 vs 有聲 EMG 波形比較

為什麼要做特徵萃取？

- 原始訊號：1000 pt/秒 × 8 通道 = 8000 維/秒
- 大量點是冗餘的，且包含與語音無關的成分

Mel 尺度的直覺

人耳對低頻分辨力強、對高頻弱 → Mel 尺度模仿此特性

計算步驟

1. 分窗：Hanning 窗，25 ms，移位 10 ms
2. **FFT**：時域 → 頻域（功率頻譜）
3. **36 個 Mel** 濾波器：計算各頻帶能量

八、資料增強 — 為什麼需要？

問題①：資料量少

只有 1 名受試者，1,238 句

→ 模型容易過擬合

問題②：Session 偏移

每次重貼電極位置不同

→ 訊號分布偏移 (Domain Shift)

問題③：訊號微弱

靜默 EMG 振幅僅有聲的 1/3–1/5

→ 訊雜比低，特徵不清晰

三種資料增強的解決策略

#	方法	解決的問題	效果
①	頻譜相減	降低背景噪訊	Baseline CER 66.5%→53.9%
②	有聲 EMG 混合 ($\gamma=0.8$)	增強微弱訊號	AuxCEMGR 額外降低 6.5%
③	Mixup ($\alpha=0.02$)	提升泛化，抑制過擬合	額外降低 1.5%

九、資料增強① — 頻譜相減



三種增強各自移除後的 CER 變化

原理：估計背景噪訊頻譜，從訊號中減去

步驟

1. 靜止時錄製背景 EMG (5 秒)
2. 計算平均背景功率頻譜 $\hat{N}(f)$
3. 每個頻率點相減，結果取零下界

$$\hat{S}(f) = \max \left(X(f) - \hat{N}(f), 0 \right)$$

- $X(f)$ ：含噪訊原始頻譜

十、資料增強② — 有聲 EMG 混合



Fig.6 — γ 值對 CER 的影響

動機：有聲 EMG 訊號較強，可增強弱訊號的訓練效果

公式

$$x_{aug} = (1 - \gamma) \cdot x_{silent} + \gamma \cdot x_{audible}$$

- $\gamma = 0.8$ （最佳值，見右圖）
- $\gamma = 0$ ：純靜默， $\gamma = 1$ ：純有聲

為什麼 $\gamma = 0.8$ 最佳？

- γ 太小：增強效果不足

十一、資料增強③ — Mixup

Fig.7 — α 值對 CER 的影響

原理：隨機混合兩個樣本的特徵和標籤

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j$$

λ 從 $\text{Beta}(\alpha, \alpha)$ 分布取樣， $\alpha = 0.02$

$\alpha=0.02$ 的含義


$\text{Beta}(0.02, 0.02)$ 是 U 形分布，極度偏向 0 或 1

→ 大多數時候幾乎只用一個樣本，偶爾才真正混合

→ 引入輕微擾動而不破壞原始樣本

效果：提升泛化，額外降低 CER ~1.5%

十二、AuxCEMGR 模型架構總覽



十三、CNN + Transformer

Fig.4 – AuxCEMGR 論文架構圖

CNN 特徵萃取層

- 2 層 2D 卷積，核大小 3×3 ，步長 2
- 每層時序壓縮一半： $T \rightarrow T/2 \rightarrow T/4$
- 輸出維度：256

Transformer 編碼器（6層）

- 自注意力機制：每個時步能看到整個序列
- 8 個注意力頭：8 個不同視角同時分析
- 位置編碼：告訴模型時間順序

Transformer vs RNN 的差異

十四、CTC 解碼器

為什麼需要 CTC ?

EMG 序列長度 ($T \approx 100$) $\neq$ 文字長度 (≈ 20) 而且沒有字元對齊標註

CTC 解法：引入空白符號 ϵ

模型每步輸出：某字元 or ϵ

輸出：你-你-好- ϵ - ϵ -世-界-界

↓ 折疊重複 + 移除 ϵ

結果：你好世界 ✓

損失函數

最大化正確序列所有可能對齊路徑的總概率

$$L_{\text{CTC}} = -\log P(y|x)$$

Beam Search 解碼 (size=5)

方法	說明	效果
Greedy	每步選最大概率	快但次優
Beam=1	等同 Greedy	同上
Beam=5	同時保留 5 條路徑	平衡最佳
Beam=50	保留 50 條	慢，邊際遞減

比喻：5 個偵探同時從現場出發，最後選最合理路線

十五、輔助任務① — 拼音 CTC



Fig.5 — η_1/η_2 超參數熱力圖

動機

- 中文字元空間：667 個（學習難度大）
- 拼音音節：僅 63 種（容易學）
- 讓模型先學「怎麼發音」，再學「對應哪個字」

做法

- Transformer 輸出後接一個拼音 CTC 分支
- 標籤：將訓練句子轉換成拼音序列
- 損失： $\eta_1 \times L_CTC_pinyin$ ($\eta_1=1.0$)

十六、輔助任務② — GRL +

Session 分類

Fig.11 — 各 Session 的 CER 比較

問題：5 個 Session 的特徵分布不同 → Domain Shift

目標：讓 CNN 學到「Session 無關」的通用特徵

梯度反轉層（GRL）原理

正向：資料原樣通過

$EMG \rightarrow CNN \rightarrow GRL \rightarrow \text{Session 分類器}$

反向：梯度乘以 -1 （反轉方向）

$CNN \leftarrow GRL \times (-1) \leftarrow \text{Session 分類器}$

結果：Session 分類器越努力辨識 → CNN 被迫學到「讓分類器更困惑」的特徵 → CNN 特徵對所有 Session 看起來都一樣

十七、訓練設定

Noam 暖機學習率排程器

$$lr = d_{model}^{-0.5} \cdot \min(step^{-0.5}, step \cdot warmup^{-1.5})$$

- warmup = 4000 步（線性升高）
- 之後按 $step^{-0.5}$ 緩慢下降

比喻：爬山先慢走確認方向，接近山頂再放慢

優化器：Adam

- $\beta_1=0.9, \beta_2=0.98, \epsilon=1e-9$
- 結合 Momentum + RMSProp 優點

其他超參數

參數	值
Batch Size	128
Dropout	0.1
Warmup Steps	4000
提前停止	連續 10 Epoch 不改善

評估指標 CER

$$CER = \frac{S + D + I}{N}$$

十八、主要實驗結果



主要結果橫條圖（越低越好）

測試集 CER 比較

模型	CER
Wadkins 2019 (LSTM+CTC)	66.8%
Baseline 無增強	66.5%
Baseline 完整增強	44.5%
AuxCEMGR 無增強	62.5%
AuxCEMGR 完整增強	38.0% ★

十九、電極通道重要性 (Fig.8)



Fig.8 — 各通道單獨使用的 CER

實驗方式：每次只用 1 個通道，測 CER

結果排名（重要性從高到低）

通道	位置	相對重要性
CH4	下巴右側	★★★★★ 最重要
CH3	下巴左側	★★★★
CH1,CH2	上嘴唇	★★★

二十、句子長度 & 跨 Session 分析



Fig.10 — 句子長度 vs CER

句子長度 vs CER (Fig.10)

- 短句（5-10 字）：CER 較低
- 長句（20+ 字）：CER 大幅上升
- 原因：CTC 對齊難度增加，Beam Search 路徑爆炸
- 改善：加入語言模型（LM）輔助解碼

跨 Session 分析 (Fig.11)

- Session 間 CER 差異最高達 $\pm 10\%$
- GRL 輔助任務有效縮小差距

二十一、結論

本研究貢獻

- 第一個中文臉部 sEMG 無聲語音辨識系統
- 最佳測試集 CER = **38.0%**
- 三種增強 + 兩個輔助任務，各自都有貢獻

研究限制

- 只有 1 名受試者
- NBA 特定語料庫
- CER 38% 仍高，實用化還有距離

未來研究方向

1. 多受試者跨人辨識
2. 加入語言模型解碼
3. 擴充語料庫（方言、日常對話）
4. 硬體微型化（可穿戴式）
5. 多模態融合（sEMG + 視訊）
6. 即時推論優化

二十二、實驗復現快速指南

```
# 環境安裝
pip install torch librosa scipy numpy jiwer

# Step 1: 訊號前處理
from scipy.signal import butter, filtfilt, iirnotch
b, a = butter(4, [10, 400], btype='band', fs=1000)
x = filtfilt(b, a, raw)
for f0 in [50, 150, 250, 350]:
    b, a = iirnotch(f0, Q=30, fs=1000)
    x = filtfilt(b, a, x)

# Step 2: MFSC 特徵萃取
import librosa
mel = librosa.filters.mel(sr=1000, n_fft=25, n_mels=36)
mfsc = librosa.feature.melspectrogram(
    y=x, sr=1000, n_mels=36, hop_length=10)
```

```
# Step 3: 模型建立 (PyTorch)
import torch.nn as nn

class AuxCEMGR(nn.Module):
    def __init__(self):
        super().__init__()
        self.cnn = nn.Sequential(
            nn.Conv2d(8, 256, 3, stride=2),
            nn.Conv2d(256, 256, 3, stride=2))
        enc = nn.TransformerEncoderLayer(
            d_model=256, nhead=8, dropout=0.1)
        self.transformer = nn.TransformerEncoder(enc, 6)
        self.ctc_char = nn.Linear(256, 667+1) # +blank
        self.ctc_pinyin = nn.Linear(256, 63+1)
        self.session_cls = nn.Linear(256, 5) # 5 sessions

# Step 4: 訓練
# Adam + Noam(warmup=4000) + Batch=128
# L = L_ctc + 1.0*L_pinyin + 1.0*L_session(GRL)
```