

用臉部肌電圖做中文無聲語音辨識

Neural Chinese Silent Speech Recognition with Facial EMG | Xie et al., 2025

陳睿莆 國立虎尾科技大學

機械與電腦輔助工程系

2026-05-15

1. 研究背景與動機
2. 資料集與硬體設備
3. 訊號前處理
4. 特徵萃取 (MFSC)
5. 資料增強 (三種方法)

1. AuxCEMGR 模型架構
2. 訓練設定與損失函數
3. 評估指標 CER
4. 實驗結果分析
5. 結論與未來方向
6. 實驗復現快速指南

定義：不發出聲音，靠感測器辨識說話意圖

→ 轉成文字

應用場景

- 喉嚨受傷、氣管切開術後無法發聲
- 高噪音環境（工廠、戰場）
- 隱密通訊

為什麼難？

- 靜默 EMG 比有聲弱 3–5 倍，SNR 低
- 中文字元龐大（本研究 667 個）
- 每次貼電極位置不同 → Session 偏移




Fig. 1. Example of facial EMG to text.

Fig.1 — EMG 訊號轉文字

sEMG（表面肌電圖）

- 偵測肌肉收縮時的微弱電訊號（0.1–5 mV）
- 非侵入式、即時、可穿戴

為什麼臉部？

- 說話時嘴唇、下巴、臉頰、喉部肌肉都會動
- 靜默時仍有微小收縮可被偵測

與其他技術的比較

喉部麥克風	需聲帶振動，完全靜默無效
EEG	解析度低、個體差異大
臉部 sEMG	輕便、準確、可穿戴 ✓




Fig. 2. Position of electrodes. The reference electrode can be located anywhere on the left clavicle. Here we only provide an example.

Fig.2 — 電極位置示意圖

現有研究的空白

- 現有 sEMG 辨識大多針對英文
- 中文 SSI 幾乎空白，[本文為首篇](#)

中文的特殊挑戰

- 字元空間龐大：[667](#) 個唯一字元
- 聲調系統：4 個聲調 + 輕聲
- 同音字：「ji」→ 雞、機、積...

Session 偏移問題 (Domain Shift)

Session 1: 電極位置 A $\rightarrow$ 分布 P_1

Session 2: 電極位置 B $\rightarrow$ 分布 P_2

$P_1 \neq P_2 \rightarrow$ 跨 Session 準確率大幅下降

本研究目標

設計能克服以上挑戰的

[第一個中文臉部 EMG SSI 系統](#)

資料集

受試者	1 名成年女性
語料庫	NBA 籃球播報語料
句子數	1,238 句
總字元	12,584 字
唯一字元	667 個
Session 數	5 (不同日期)
資料分割	訓練:驗證:測試=7:1:2

Neuracle NSW308M

採樣率	1000 Hz
通道數	8 通道
電極	Ag/AgCl
訊號振幅	0.1–5 mV

電極位置

- CH1–CH2: 上嘴唇 (口輪匝肌)
- CH3–CH4: 下巴 (**CH4 最重要**)
- CH5–CH6: 喉部 (靜默時幾乎不動)
- CH7–CH8: 臉頰 (顴大肌)

問題：原始 EMG 充滿雜訊

- 工頻電磁干擾 (50 Hz 及諧波)
- 基線漂移 (< 10 Hz)
- 高頻噪訊 (> 400 Hz)

Butterworth 帶通濾波 (10–400 Hz)

```
from scipy.signal import butter, filtfilt
b, a = butter(4, [10, 400],
              btype='band', fs=1000)
x = filtfilt(b, a, raw_signal)
```

4 階：截止斜率 -80 dB/decade，銳利不影響主頻段

Notch 陷波濾波 (50/150/250/350 Hz)

```
from scipy.signal import iirnotch
for f0 in [50, 150, 250, 350]:
    b, a = iirnotch(f0, Q=30, fs=1000)
    x = filtfilt(b, a, x)
```

Q=30：陷波寬度 $\approx \pm 0.83$ Hz，精準去除工頻

前處理流程

原始 EMG

- Butterworth 帶通 (10–400 Hz)
- Notch $\times 4$ (50/150/250/350 Hz)
- 分段切割 (依句子邊界)

為什麼做特徵萃取?

- 原始: 1000 pt/秒 $\times$ 8 通道, 維度高且冗餘
- MFSC: 36 維/時步, 有意義的壓縮表徵

計算步驟

1. 分窗: Hanning 窗, 25 ms, 移位 10 ms
2. **FFT**: 時域 $\rightarrow$ 功率頻譜
3. **36 個 Mel 濾波器**: 計算各頻帶能量
4. 取對數: 模仿人耳的對數感知

輸出: 8 通道 $\times$ T 時步 $\times$ **36 維**




Fig. 3. Clean EMG of silent speech and vocalized speech for the text 目下正合上一步

Fig.3 — 靜默 vs 有聲 EMG 波形

靜默 EMG 振幅約為有聲的 **1/3–1/5**
→ SSI 比有聲辨識更難的根本原因

方法	原理	關鍵參數	效果 (CER)
① 頻譜相減	估計背景噪訊頻譜並減去	—	66.5% → 53.9%
② 有聲 EMG 混合	按比例混入有聲說話 EMG	$\gamma = 0.8$	AuxCEMGR 降 6.5%
③ Mixup	兩樣本特徵和標籤插值混合	$\alpha = 0.02$	額外降 1.5%

① 頻譜相減公式

$$\hat{S}(f) = \max(X(f) - \hat{N}(f), 0)$$

$X(f)$: 含噪訊頻譜, $\hat{N}(f)$: 背景噪訊估計

② 有聲混合 & ③ Mixup

$$x_{\text{aug}} = (1 - \gamma) \cdot x_{\text{silent}} + \gamma \cdot x_{\text{audible}}$$

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j, \quad \lambda \sim \text{Beta}(\alpha, \alpha)$$

② $\gamma=0.8$ 為什麼最佳?

- $\gamma=0$: 純靜默，訓練訊號仍微弱
- $\gamma=0.8$: 甜蜜點，增強足夠且不過度
- $\gamma=1.0$: 訓練/測試分布差距最大，泛化差

③ $\alpha=0.02$ 的含義

- Beta(0.02, 0.02) 是 U 形分布
- 大多數時候 $\lambda \approx 0$ 或 1 (幾乎不混合)
- 偶爾才真正混合兩個樣本
- 效果: 輕微擾動，提升泛化，不破壞原始樣本

三種增強的相對重要性

頻譜相減 > 有聲 EMG 混合 > Mixup

三者相互補充，缺一效果均下降




Fig. 6. CER of weight γ in audible data. γ is set to 0.2, 0.4, 0.6, 0.8, 1.2. Here we report the result on the baseline model and AuxCEMGR.

Fig.6 — γ 值對 CER 的影響




Fig. 7. CER of α in mixup. α is set to 0, 0.01, 0.02, 0.05, 0.1, 0.2, 0.3, 0.4.

Fig.7 — α 值對 CER 的影響

全名: Auxiliary-task Cascaded EMG Recognizer

主流程 (由左至右)

1. **CNN (2 層)**: 提取局部肌肉動作模式 (步長=2, 壓縮 $T \rightarrow T/4$)
2. **Transformer (6 層, 8 頭)**: 捕捉全局時序依賴
3. **CTC 解碼器**: 輸出中文字元序列

兩個輔助任務 (並行分支)

- **拼音 CTC**: 輔助學習音韻 ($\eta_1=1.0$)
- **GRL + Session 分類**: 消除偏移 ($\eta_2=1.0$)

總損失函數

$$L_{\text{total}} = L_{\text{CTC}}^{\text{char}} + \eta_1 L_{\text{CTC}}^{\text{pinyin}} + \eta_2 L_{\text{session}}$$





Fig. 4. Our AuxCEMGR model, which consists of a baseline transformer-based CTC model for EMG-to-text as well as two auxiliary tasks: Pinyin generation and session classification.

Fig.4 — 論文原始架構圖

AuxCEMGR 模型架構示意圖



架構示意（自製）

為什麼需要 CTC?

- EMG 序列長度 ($T \approx 100$) $\neq$ 文字長度 (≈ 20)
- 而且沒有字元對齊標註

CTC 解法：引入空白符號 ϵ

模型每步輸出：某字元 or ϵ

輸出：你-你-好- ϵ - ϵ -世-界

折疊：你好世界 ✓

損失函數

$$L_{\text{CTC}} = -\log P(y \mid x)$$

最大化正確序列所有對齊路徑的總概率

Beam Search (size=5)

方法	說明	效果
Greedy	每步選最高概率	快但次優
Beam=1	等同 Greedy	同上
Beam=5	同時保留 5 條路徑	最佳平衡
Beam=50	保留 50 條	慢，邊際遞減

比喻：5 個偵探同時出發，選最合理路線

① 拼音 CTC ($\eta_1=1.0$)

- 動機：667 個字元難學，拼音只有 63 種
- 做法：Transformer 輸出後接拼音 CTC 分支
- 讓模型先學「怎麼發音」再學「對應哪個字」




Fig. 5. CER of AuxCEMGR model. Here we set the η_1, η_2 to 0, 0.25, 0.50, 0.75, 1.00, 1.25, 1.50, 2.00, respectively.

Fig.5 — η_1/η_2 熱力圖，最佳為 1.0/1.0

② GRL + Session 分類 ($\eta_2=1.0$)

問題：5 個 Session 特徵分布不同 $\rightarrow$ Domain Shift

梯度反轉層 (GRL) 工作原理

正向：資料原樣通過

反向：梯度乘以 -1 (方向反轉)

結果：CNN 被迫學到「讓 Session 分類器困惑」的特徵

$\rightarrow$ **Domain Invariant** 特徵

比喻：反間諜訓練

Noam 暖機學習率排程器

$$\text{lr} = d_{\text{model}}^{-0.5} \cdot \min(t^{-0.5}, t \cdot \text{warmup}^{-1.5})$$

- $d_{\text{model}} = 256$, warmup = 4000 步
- 前 4000 步線性升高 → 之後緩慢下降

優化器：Adam

- $\beta_1=0.9$, $\beta_2=0.98$, $\varepsilon=1\text{e-}9$

評估指標：CER

$$\text{CER} = \frac{S + D + I}{N}$$

S 替換，D 刪除，I 插入，N 總字元數


超參數總覽

參數	值
Batch Size	128
Dropout	0.1
Warmup Steps	4000
d_model	256
Transformer 層數	6
注意力頭數	8
η_1 / η_2	1.0 / 1.0
提前停止	10 Epoch

模型	CER
Wadkins 2019 (LSTM+CTC)	66.8%
Baseline 無增強	66.5%
Baseline 完整增強	44.5%
AuxCEMGR 無增強	62.5%
AuxCEMGR 完整增強	38.0% ★

關鍵結論

- AuxCEMGR 無增強比 Baseline 差 → 模型與增強須搭配
- 模型 + 增強缺一不可
- 比 Wadkins 2019 改善 28.8 個百分點



主要結果橫條圖 (越低越好)

電極通道重要性 (Fig.8)

通道	位置	重要性
CH4	下巴右	★★★★★ 最重要
CH3	下巴左	★★★★
CH1,CH2	上嘴唇	★★★
CH7,CH8	臉頰	★★
CH5,CH6	喉部	★ 最不重要

句子長度 vs CER (Fig.10)

- 短句 CER 低，長句 CER 大幅上升
- 改善方向：加入語言模型 (LM) 輔助解碼




Fig. 8. CER of Channel 1 to Channel 8.

Fig.8 — 各通道單獨 CER




Fig. 10. CER of sentence lengths in the baseline and AuxCEMGR with different settings. We classify the test set into six categories according to text length.

Fig.10 — 句子長度 vs CER

主要貢獻

- 第一個中文臉部 sEMG 無聲語音辨識系統
- 最佳測試集 CER = **38.0%**
- 三種增強 + 兩個輔助任務，各自都有貢獻

研究限制

- 只有 1 名受試者（跨人泛化未知）
- NBA 特定語料庫
- CER 38% 實用化仍有距離

未來研究方向

1. 多受試者跨人辨識
2. 加入語言模型解碼
3. 擴充語料庫（方言、日常）
4. 硬體微型化（可穿戴式）
5. 多模態融合（sEMG + 視訊）
6. 即時推論（Online）

環境安裝

```
pip install torch librosa scipy numpy jiwer
```

Step 1: 訊號前處理

```
from scipy.signal import butter, filtfilt, iirnotch
b, a = butter(4, [10, 400], btype='band', fs=1000)
x = filtfilt(b, a, raw)
for f0 in [50, 150, 250, 350]:
    b, a = iirnotch(f0, Q=30, fs=1000)
    x = filtfilt(b, a, x)
```

Step 2: MFSC

```
mfsc = librosa.feature.melspectrogram(
    y=x, sr=1000, n_mels=36, hop_length=10)
```

Step 3: 模型建立

```
class AuxCEMGR(nn.Module):
    def __init__(self):
        super().__init__()
        self.cnn = nn.Sequential(
            nn.Conv2d(8, 256, 3, stride=2),
            nn.Conv2d(256, 256, 3, stride=2))
        enc = nn.TransformerEncoderLayer(
            d_model=256, nhead=8, dropout=0.1)
        self.enc = nn.TransformerEncoder(enc, 6)
        self.ctc = nn.Linear(256, 668)
        self.pinyin = nn.Linear(256, 64)
        self.session = nn.Linear(256, 5)
```

Step 4: 訓練

```
# Adam + Noam(warmup=4000) + Batch=128
# L = L_ctc + 1.0*L_py + 1.0*L_sess(GRL)
# Beam Search(size=5) → 評估 CER
```